

Cahier des Charges

Projet de Fin d'Études

Conception et Implémentation d'une Plateforme
d'Agents IA Métiers basée sur LLM, RAG et Orchestration de
Workflows

Entreprise : Welyne



Encadré par : Ben Ammar Nermine

Durée : 4 - 5 mois
Niveau : Ingénieur

1. Contexte et Objectifs du Projet

Avec l'émergence des Large Language Models (LLM) et des architectures basées sur le Retrieval-Augmented Generation (RAG), les entreprises cherchent à automatiser leurs processus métiers complexes à travers des agents intelligents capables de raisonner, inter-agir avec des données internes et exécuter des actions via des APIs.

Cependant, la majorité des solutions existantes sont soit génériques, soit difficilement intégrables aux environnements métiers spécifiques.

Ce projet vise à concevoir et implémenter une plateforme SaaS permettant aux entreprises de créer, configurer et déployer des Agents IA Métiers capables de :

- Automatiser des tâches complexes,
- Interagir avec des bases de données et APIs,
- Exploiter des documents internes via RAG,
- Orchestrer des workflows métiers dynamiques,
- Fournir des réponses explicables et traçables.

L'objectif principal est de développer une architecture complète, modulaire et scalable orientée SaaS.

2. Périmètre Fonctionnel

2.1 Gestion Multi-tenant

La plateforme devra :

- Permettre l'inscription et l'authentification des entreprises,
- Isoler les données par organisation,
- Gérer les rôles (Admin, Manager, Utilisateur),
- Permettre la gestion d'abonnements.

2.2 Module Agent IA

Chaque entreprise pourra créer des agents configurables :

- Définition du rôle et des instructions système,
- Connexion à des sources de données internes,
- Activation de modules RAG,
- Connexion à des APIs externes,
- Paramétrage du niveau d'autonomie.

2.3 Module RAG (Retrieval-Augmented Generation)

Le système devra permettre :

- Upload de documents (PDF, DOCX, CSV),
- Indexation dans une base vectorielle,
- Recherche sémantique,
- Injection du contexte pertinent dans le prompt LLM,
- Traçabilité des sources utilisées.

2.4 Orchestration de Workflows

La plateforme intégrera un moteur de workflow permettant :

- Définition d'actions conditionnelles,
- Appel dynamique d'APIs,
- Enchaînement multi-agents,
- Déclenchement automatique (event-driven),
- Logs détaillés des exécutions.

2.5 Interface Conversationnelle

Un espace chat intelligent permettra :

- Interaction en langage naturel,
- Appel automatique des outils (tool calling),
- Consultation des documents indexés,
- Exécution de workflows,
- Historique des conversations.

2.6 Monitoring et Observabilité

Le système devra inclure :

- Suivi des requêtes LLM,
- Analyse des coûts d'inférence,
- Journalisation des actions,
- Dashboard de performance des agents.

3. Architecture Technique

L'architecture reposera sur une approche microservices et orientée API :

- Frontend : React.js (Application SaaS moderne)
- Backend : FastAPI
- LLM : API OpenAI ou modèle open-source
- Orchestration : LangChain / LangGraph

- Base vectorielle : Pinecone / Weaviate / Chroma
- Base de données : PostgreSQL
- Authentification : JWT
- Déploiement : Docker + Cloud (AWS / Azure)

L'architecture sera composée de :

- Couche Interface Utilisateur,
- Couche API Backend,
- Couche Agent Orchestration,
- Couche RAG,
- Couche Données,
- Couche Monitoring.

4. Sécurité

La plateforme devra garantir :

- Isolation des données par tenant,
- Gestion sécurisée des clés API,
- Contrôle d'accès basé sur rôles,
- Protection contre les injections prompt,
- Journalisation des accès sensibles.

5. Livrables Attendus

À l'issue du stage :

- Plateforme SaaS fonctionnelle,
- Système d'agents IA configurables,
- Module RAG opérationnel,
- Moteur de workflow intégré,
- Interface conversationnelle complète,
- Dashboard de monitoring,
- Code source documenté,
- Documentation technique,
- Rapport de stage,
- Démonstration live du produit.

6. Compétences Requises

- Maîtrise de Python et développement API,
- Connaissances en LLM et RAG,
- Notions d'architecture SaaS,
- Bases en bases de données relationnelles et vectorielles,
- Développement frontend moderne,
- Compréhension des workflows automatisés.